

ПРВИ ТЕСТ

Самообучавајући и адаптивни алгоритми
Катедра за аутоматско управљање • ФТН, Нови Сад

Име и презиме: _____

Број индекса: _____

1. Заокружити тачне тврдње:

- а) ε -похлепна политика је за $\varepsilon = 1$ идентична насумичној политици.
- б) Белманова једначина за одређивање вредности стања у детерминистичком случају је линеарна.
- в) Вредност акције “а” у стању “s”, при политици одлучивања π је добит коју агент остварује уколико од полазног временског тренутка (када се налази у стању “s”) па до краја примењује политику π .
- г) Стохастичка политика одлучивања дефинише начин на који агент доноси одлуку у сваком уоченом стању окружења.

Решење: Тачне су тврдње а) и г). Појашњење је дато испод.

- а) Тачно — када је $\varepsilon = 1$, ε -похлепна политика бира акције потпуно насумично, па је еквивалентна насумичној политици.
- б) Нетачно — Белманова једначина је уопштено нелинеарна због појављивања максимума унутар вредносне функције.
- в) Нетачно — вредност акције $q_\pi(s, a)$ подразумева да се најпре извршава конкретна акција a у стању s , а тек након тога прати политика π , што није исто што и праћење политике π од самог почетка.
- г) Тачно — стохастичка политика одређује вероватноћу избора одређене акције у сваком стању, дакле описује како агент доноси одлуке у окружењу.

2. За стохастички процес одлучивања и дату детерминистичку политику π , формирати Белманову једначину за одређивање вредности акција у стањима и **објаснити све ознаке** у том запису.

Решење: Тражена Белманова једначина има следећи облик

$$q_\pi(s, a) = \sum_{\substack{s^+ \in S^+ \\ r \in R}} p(s^+, r | s, a) [r + \gamma q_\pi(s^+, \pi(s^+))].$$

$q_\pi(s, a)$ је вредност акције a у стању s — очекивана укупна дисконтована добит ако се у стању s изврши акција a , а затим прати политика π .

s је тренутно стање система.

a је акција која се извршава у стању s .

$\pi(s^+)$ је акција коју одређује детерминистичка политика π у наредном стању s^+ .

$s^+ \in S^+$ је наредно (будуће) стање, које припада скупу свих могућих наредних стања S^+ .

$r \in R$ је непосредна награда након преласка из стања s у s^+ применом акције a , из скупа могућих награда R .

$p(s^+, r|s, a)$ је вероватноћа да ће из стања s , након извршења акције a , систем прећи у стање s^+ и примити награду r .

γ је дисконтни фактор, где $0 \leq \gamma \leq 1$, којим се умањују будуће награде.

3. Дефинисати добит код стохастичког Марковљевог процеса одлучивања (МПО) и **објаснити све ознаке** у том запису.

Решење: Добит код стохастичког МПО се дефинише као

$$g = E \left\{ \sum_{k=0}^T \gamma^k R_k \right\}.$$

g је очекивана укупна дисконтована добит коју агент остварује током епизоде.

$E \{ \cdot \}$ је математичко очекивање — просечна вредност у случају стохастичког окружења.

$\sum_{k=0}^T$ је збир добити по корацима од почетног тренутка ($k = 0$) до краја епизоде ($k = T$).


γ^k је дисконтни фактор подигнут на k — вредност у интервалу $[0, 1]$ којом се умањује значај будућих награда; често моделује стрпљивост агента.

R_k је награда коју агент добија у кораку k .

T је крајњи корак (дужина епизоде) — може бити коначан или бесконачан, у зависности од модела.

4. МПО је приказан графом на слици 1. Стања су означена на чворовима графа, док су могуће акције означене врстом везе (акција “+” је приказана пуном, док је акција “-” приказана испрекиданом линијом). Прелази означени пуном линијом наплаћују се са -2, а са испрекиданом линијом -1. За дати МПО:

- а) Записати систем Белманових једначина и израчунати вредности свих стања за политику “У сваком стању користити акцију +”. Користити фактор обезвређивања 0.9. Сматрати да терминално стање има вредност 0.
- б) Записати систем Белманових једначина за одређивање оптималних вредности свих стања и израчунати их. Користити фактор обезвређивања 0.9. Сматрати да терминално стање има вредност 0.
- в) Одредити оптималну политику.



Слика 1: Пример графа који приказује МПО-а из задатка 4.

Решење:

- а) Белманова једначина, у општем случају, за одређивање вредности стања s при фиксној политици $\pi(s)$ је

$$v_{\pi}(s) = h(s, \pi(s)) + \gamma v_{\pi}(f(s, \pi(s))),$$

где је $h(s, \pi(s))$ непосредна награда у стању s при избору акције $\pi(s)$, а $f(s, \pi(s))$ наредно стање у које се доспева применом акције $\pi(s)$ у стању s . Када применимо одговарајућу Белманову једначину на наш задатак, добијамо следећи систем једначина

$$\begin{aligned} v_{\pi}(A) &= h(A, \pi(A)) + \gamma v_{\pi}(f(A, \pi(A))) = -2 + 0.9v_{\pi}(C) \\ v_{\pi}(B) &= h(B, \pi(B)) + \gamma v_{\pi}(f(B, \pi(B))) = -2 + 0.9v_{\pi}(A) \\ v_{\pi}(C) &= h(C, \pi(C)) + \gamma v_{\pi}(f(C, \pi(C))) = -2 + 0.9v_{\pi}(T) = -2. \end{aligned}$$

Одатле следи да су вредности стања при фиксној политици $\pi(s)$ “У сваком стању користити акцију +”

$$v_{\pi}(A) = -3.8$$

$$v_{\pi}(B) = -5.42$$

$$v_{\pi}(C) = -2.$$

- б) Белманова једначина за одређивање оптималне вредности стања s је

$$v^*(s) = \max_{a \in A} \{h(s, a) + \gamma v^*(f(s, a))\},$$

где је $h(s, a)$ непосредна награда у стању s при избору акције a , а $f(s, a)$ наредно стање у које се доспева применом акције a у стању s . Када применимо одговарајућу Белманову једначину на наш задатак, добијамо следећи систем једначина

$$v^*(A) = \max_{a \in \{+, -\}} \{h(A, +) + \gamma v^*(f(A, +)), h(A, -) + \gamma v^*(f(A, -))\}$$

$$= \max_{a \in \{+, -\}} \left\{ -2 + 0.9v^*(C), -1 + 0.9 \underbrace{v^*(T)}_0 \right\},$$

$$v^*(B) = \max_{a \in \{+, -\}} \{h(B, +) + \gamma v^*(f(B, +)), h(B, -) + \gamma v^*(f(B, -))\}$$

$$= \max_{a \in \{+, -\}} \{-2 + 0.9v^*(A), -1 + 0.9v^*(C)\},$$

$$v^*(C) = \max_{a \in \{+, -\}} \{h(C, +) + \gamma v^*(f(C, +)), h(C, -) + \gamma v^*(f(C, -))\}$$

$$= \max_{a \in \{+, -\}} \left\{ -2 + 0.9 \underbrace{v^*(T)}_0, -1 + 0.9v^*(B) \right\}.$$

До решења се долази једноставно, применом алгоритма итерирања по вредностима на функцију вредности стања. Претпоставимо да су иницијално оптималне вредности свих стања нпр. једнаке нули. Односно иницијално важи да је $v^*(A) = v^*(B) = v^*(C) = 0$. Кроз четири итерације долази се до оптималног решења. Поступак је следећи:

Итерација	$v^*(A)$	$v^*(B)$	$v^*(C)$
0	0	0	0
1	$\max\{-2 + 0.9 \cdot 0, -1 + 0.9 \cdot 0\} = -1$	$\max\{-2 + 0.9 \cdot 0, -1 + 0.9 \cdot 0\} = -1$	$\max\{-2 + 0.9 \cdot 0, -1 + 0.9 \cdot 0\} = -1$
2	$\max\{-2 + 0.9 \cdot (-1), -1 + 0.9 \cdot 0\} = -1$	$\max\{-2 + 0.9 \cdot (-1), -1 + 0.9 \cdot (-1)\} = -1.9$	$\max\{-2 + 0.9 \cdot 0, -1 + 0.9 \cdot (-1)\} = -1.9$
3	$\max\{-2 + 0.9 \cdot (-1.9), -1 + 0.9 \cdot 0\} = -1$	$\max\{-2 + 0.9 \cdot (-1), -1 + 0.9 \cdot (-1.9)\} = -2.71$	$\max\{-2 + 0.9 \cdot 0, -1 + 0.9 \cdot (-1.9)\} = -2$
4	$\max\{-2 + 0.9 \cdot (-2), -1 + 0.9 \cdot 0\} = -1$	$\max\{-2 + 0.9 \cdot (-1), -1 + 0.9 \cdot (-2)\} = -2.8$	$\max\{-2 + 0.9 \cdot 0, -1 + 0.9 \cdot (-2.71)\} = -2$
5	-1	-2.8	-2

Дакле, добијамо оптималне вредности стања

$$v^*(A) = -1$$

$$v^*(B) = -2.8$$

$$v^*(C) = -2.$$

- в) На основу дела под б) закључује се да је оптимална политика дефинисана на следећи начин:

s	$\pi^*(s)$
A	$-$
B	$-$
C	$+$


5. Детерминистички МПО је дефинисан следећом табелом.

стање	акција	нередно ст.	награда
S_1	a_1	S_1	-1
S_1	a_2	S_2	-2
S_1	a_3	T	-1
S_2	a_1	S_3	-3
S_2	a_2	S_1	0
S_2	a_3	S_2	-1
S_3	a_1	S_3	-3
S_3	a_2	S_2	-2
S_3	a_3	T	-1

- а) Нацртати дати МПО у виду графа.
б) На основу добијеног модела формирати Q –табелу, при политици “У сваком стању бирати акцију a_1 ”.
в) У случају да немамо модел Марковљевог процеса одлучивања, него само Q –табелу, да ли имамо све информације потребне за доношење одлуке? Ако је одговор НЕ, **образложити** шта је још неопходно.
г) Математички записати општи израз за оптималну вредност стања. Затим тај израз применити (не треба рачунати) за стање S_1 (вредност терминалног стања је нула), $\gamma = 0.9$.

Решење:

- а) Дати МПО можемо графички приказати као на слици испод. Одговарајуће акције назначене су линијама (прелазима) различитих боја: акција a_1 црвеном, a_2 плавом и a_3 зеленом бојом. Поред сваке акције (прелаза) стоји број који означава колика је одговарајућа награда.



Слика 2: Решење 5. задатка под а).

б)

$$\begin{aligned}
 q_\pi(S_1, a_1) &= r + \gamma q_\pi(S_1, a_1) = -1 + 0.9q_\pi(S_1, a_1) \\
 q_\pi(S_1, a_2) &= r + \gamma q_\pi(S_2, a_1) = -2 + 0.9q_\pi(S_2, a_1) \\
 q_\pi(S_1, a_3) &= r + \underbrace{\gamma q_\pi(T, a_1)}_0 = -1 \\
 q_\pi(S_2, a_1) &= r + \gamma q_\pi(S_3, a_1) = -3 + 0.9q_\pi(S_1, a_1) \\
 q_\pi(S_2, a_2) &= r + \gamma q_\pi(S_1, a_1) = 0 + 0.9q_\pi(S_1, a_1) \\
 q_\pi(S_2, a_3) &= r + \gamma q_\pi(S_2, a_1) = -1 + 0.9q_\pi(S_1, a_1) \\
 q_\pi(S_3, a_1) &= r + \gamma q_\pi(S_3, a_1) = -3 + 0.9q_\pi(S_3, a_1) \\
 q_\pi(S_3, a_2) &= r + \gamma q_\pi(S_2, a_1) = -2 + 0.9q_\pi(S_2, a_1) \\
 q_\pi(S_3, a_3) &= r + \underbrace{\gamma q_\pi(T, a_1)}_0 = -1.
 \end{aligned}$$

Решавањем овог линеарног система једначина, долазимо до тражене Q -табеле.

s	a	$q_\pi(s, a)$
S_1	a_1	-10
S_1	a_2	-29
S_1	a_3	-1
S_2	a_1	-30
S_2	a_2	-9
S_2	a_3	-28
S_3	a_1	-30
S_3	a_2	-29
S_3	a_3	-1

- в) Када имамо Q -табелу, имамо све информације које су нам потребне за доношење одлуке.
- г) Општи израз за оптималну вредност стања, у нашем детерминистичком случају, дефинише се Белмановом једначином

$$v^*(s) = \max_{a \in A} \{h(s, a) + \gamma v^*(f(s, a))\}.$$

Када израз применимо на стање S_1 добијамо

$$v^*(S_1) = \max_{a \in \{a_1, a_2, a_3\}} \{h(S_1, a) + \gamma v^*(f(S_1, a))\}.$$

6. Дат је МПО, са скупом могућих стања $\mathcal{S} = \{A, B, C, D\}$, скупом могућих акција $\mathcal{A} = \{+, -\}$ и скупом могућих награда $\mathcal{R} = \{-2, -1, 0, 1, 2\}$. Праћењем дејства агента, уочене су следеће секвенце стања, акција и награда:

$$\begin{aligned} A &\xrightarrow[-2]{-} B \xrightarrow[-1]{-} C \xrightarrow[-1]{-} D \xrightarrow[-1]{+} T, & (\text{виђено 50 пута}) \\ &C \xrightarrow[-2]{+} B \xrightarrow[+2]{+} T, & (\text{виђено 30 пута}) \\ C &\xrightarrow[+1]{-} A \xrightarrow[-1]{-} C \xrightarrow[-2]{+} D \xrightarrow[+1]{+} T, & (\text{виђено 10 пута}) \\ A &\xrightarrow[-1]{-} C \xrightarrow[-2]{+} B \xrightarrow[-2]{-} T, & (\text{виђено 40 пута}) \\ A &\xrightarrow[-1]{+} B \xrightarrow[+1]{+} A \xrightarrow[+1]{-} T, & (\text{виђено 15 пута}) \end{aligned}$$

Свака стрелица представља један прелаз између стања. Ознака изнад стрелице означава акцију која је довела до прелаза, а број испод стрелице означава остварену награду. T је терминално "стање". На основу искуства стеченог посматрањем ових секвенци, закључите:

- Који тип МПО је представљен?
- Коју политику одлучивања користи агент?
- Одредити агентову политику на основу виђених секвенци.

Решење:

- Представљен је стохастички МПО. То једноставно можемо уочити на основу тога како када се нађемо више пута у истом стању и применимо исту акцију, завршавамо у другачијим стањима.
- Агент користи стохастичку политику. То примећујемо на основу тога што у истом стању примећујемо да су вршене другачије акције.

в) На основу виђених секвенци можемо одредити агентову политику.

s	a	$\pi(a s)$
A	$+$	$\frac{15}{130}$
A	$-$	$\frac{115}{130}$
B	$+$	$\frac{45}{135}$
B	$-$	$\frac{90}{135}$
C	$+$	$\frac{8}{13}$
C	$-$	$\frac{5}{13}$
D	$+$	1
D	$-$	0